

Diseño ordenado SIR

Daniel Czarniewicz

2017

Estrategia de selección

Se realizan m extracciones con reposición de una población de tamaño N . En cada extracción, el k -ésimo elemento tiene probabilidad $p_k = 1/N$ de ser seleccionado. Dado que se muestrea con reposición, los elementos pueden ser extraídos más de una vez. El mecanismo de extracción genera una *muestra ordenada*: $os = \{k_1; \dots; k_i; \dots; k_m\}$.

Se define la variable aleatoria r_k , la cual mide la cantidad de veces que el elemento k es sorteado. Por lo tanto, $r_k \sim \text{Bin}(m; 1/N)$. Si N es lo suficientemente grande, esta probabilidad puede aproximarse mediante una distribución Poisson: $r_k \stackrel{a}{\sim} \text{Poisson}(m/N)$. Dada la distribución Binomial de r_k ,

$$P(\text{"extraer } r_k \text{ veces el elemento } k") = \binom{m}{r} \left(\frac{1}{N}\right)^r \left(1 - \frac{1}{N}\right)^{m-r}$$
$$\star E(r_k) = \frac{m}{N} \quad \star V(r_k) = \frac{m}{N} \left(1 - \frac{1}{N}\right) \doteq \frac{m}{N}$$

La probabilidad de que el elemento k nunca sea seleccionado en las m extracciones es:

$$P(\text{"no seleccionar } k \text{ en ninguna de las } m \text{ extracciones"}) = \left(1 - \frac{1}{N}\right)^m$$

Mientras que:

$$P(\text{"el elemento } k \text{ sea extraído"}) = P(r_k \geq 1) = 1 - P(r_k < 1) = 1 - P(r_k = 0) = 1 - \left(1 - \frac{1}{N}\right)^m$$

En cada una de las extracciones, la probabilidad de que el elemento k sea seleccionado es p_k , donde $\sum_U p_k = 1$.

De esta forma $p(os) = \prod_{i=1}^m p_{k_i}$. En el diseño ordenado *SIR*, los p_k se eligen de forma que todos los elementos tengan la misma probabilidad de ser seleccionados, por lo tanto: $p_k = 1/N$.

Dado que existen N^m muestras ordenadas de largo m , y las mismas son equiprobables, la probabilidad de seleccionar una muestra ordenada cualquiera es:

$$p(os) = \begin{cases} N^{-m} & \text{si la muestra ordenada es de tamaño } m \\ 0 & \text{en otro caso} \end{cases}$$

Cada muestra ordenada, os , induce una muestra, s , tal que

$$s = \{k : k = k_i \text{ para algún } i = 1; \dots; m\}$$

Probabilidades de inclusión

Las probabilidades de inclusión de primer orden son:

$$\star \pi_k = P(k \in s) = P(r_k \geq 1) = 1 - \left(1 - \frac{1}{N}\right)^m \quad \forall k \in U$$

Las probabilidades de inclusión de segundo orden son:

$$\star \pi_{kl} = P(k; l \in s) = 1 - \left[2 \left(1 - \frac{1}{N} \right)^m - \left(1 - \frac{1}{N} \right)^{2m} \right] \quad \forall k \neq l \in U$$

El estimador \hat{t}_{pwr}

$$\begin{aligned} \star \hat{t}_{pwr} &= \frac{1}{m} \sum_{i=1}^m \frac{y_{k_i}}{p_{k_i}} = \frac{N}{m} \sum_{i=1}^m y_{k_i} = N \bar{y}_{os} \\ \star V_1 &= \sum_U \left(\frac{y_k}{p_k} - t_y \right)^2 p_k = \frac{1}{N} \sum_U \left(N y_k - N \bar{y}_U \right)^2 = N(N-1) S_{yU}^2 \\ \star V_{SIR}(\hat{t}_{pwr}) &= \frac{V_1}{m} = \frac{N}{m} (N-1) S_{yU}^2 \\ \star \hat{V}_1 &= \frac{1}{m-1} \sum_{i=1}^m \left(\frac{y_{k_i}}{p_{k_i}} - \hat{t}_{pwr} \right)^2 = \frac{1}{m-1} \sum_{i=1}^m \left(N y_{k_i} - N \bar{y}_{os} \right)^2 = N^2 S_{y_{os}}^2 \\ \star \hat{V}_{SIR}(\hat{t}_{pwr}) &= \frac{\hat{V}_1}{m} = \frac{N^2}{m} S_{y_{os}}^2 \quad \text{donde} \quad S_{y_{os}}^2 = \frac{1}{m-1} \sum_{i=1}^m \left(y_{k_i} - \bar{y}_{os} \right)^2 \end{aligned}$$

El estimador \hat{y}_U

$$\begin{aligned} \star \hat{y}_U &= \frac{\hat{t}_{pwr}}{N} \\ \star V_{SIR}(\hat{y}_U) &= V_{SIR} \left(\frac{\hat{t}_{pwr}}{N} \right) = \frac{1}{N^2} V_{SIR}(\hat{t}_{pwr}) = \frac{1}{N^2} \frac{V_1}{m} = \frac{N-1}{Nm} S_{yU}^2 \\ \star \hat{V}_{SIR}(\hat{y}_U) &= \hat{V}_{SIR} \left(\frac{\hat{t}_{pwr}}{N} \right) = \frac{1}{N^2} \hat{V}_{SIR}(\hat{t}_{pwr}) = \frac{1}{N^2} \frac{\hat{V}_1}{m} = \frac{N^2 S_{y_{os}}^2}{N^2 m} = \frac{S_{y_{os}}^2}{m} \end{aligned}$$

El estimador \hat{t}_π

Para derivar el estimador π del total se debe trabajar con la muestra (s) inducida por el diseño ordenado. Dado que los elementos podrían repetirse, n_S es aleatoria. Para $m \geq 2$, \hat{t}_{pwr} y \hat{t}_π no tienen por qué coincidir.

$$\star \hat{t}_\pi = \sum_s y_k^\vee = \sum_s \frac{y_k}{\pi_k} = \sum_s \frac{y_k}{1 - \left(1 - \frac{1}{N} \right)^m}$$

El estimador \hat{t}_{alt}

Otro estimador insesgado pasado en el muestra s es el estimador \hat{t}_{alt} , donde:

$$\star \hat{t}_{alt} = N \bar{y}_s = \frac{N}{n_s} \sum_s y_k$$

Si $E_{SIR}(n_S) = n = N \left[1 - \left(1 - \frac{1}{N} \right)^m \right]$, entonces $\hat{t}_{alt} = \frac{n}{n_s} \hat{t}_\pi$

Efecto diseño

Si $m = n$:

$$\star \frac{V_{SIR}(\hat{t}_{pur})}{V_{SI}(\hat{t}_{\pi})} = \frac{\frac{N}{m}(N-1)S_{yU}^2}{\frac{N^2}{n}(1-f)S_{yU}^2} = \frac{N-1}{N} \frac{1}{1-f} \doteq \frac{1}{1-f}$$

Tamaño muestral

En caso que se quiera estimar t_y utilizando \hat{t}_{pur} bajo un diseño SIR con m extracciones:

$$\star \varepsilon^2 \doteq z_{1-\alpha/2}^2 V_{SIR}(\hat{t}_y) = z_{1-\alpha/2}^2 N(N-1) \frac{S_{yU}^2}{m} \Rightarrow m = \frac{1}{\varepsilon^2} \left[z_{1-\alpha/2}^2 N(N-1) S_{yU}^2 \right]$$